

### Procesamiento de datos con R

Clase: Introducción a R

Orlando Joaqui Barandica

Universidad del Valle

2023



### Contenido



- 1 Introducción
- 2 Elementos en R
- 3 Objetos en R
- 4 Indexado
- 5 Valores perdidos
- 6 Importar datos en R

### Contenido



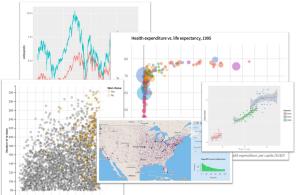
- 1 Introducción
- 2 Elementos en R
- 3 Objetos en R
- 4 Indexado
- 5 Valores perdidos
- 6 Importar datos en R





Qué hay detrás de las estadísticas... De las predicciones... De las representaciones... en las que se basan los mejores científicos, analistas, estadísticos, emprendedores, etc.. a la hora de tomar decisiones.

Quizás no sea muy visible pero está ahí. Se llama R.





### Qué es R?



- R es un conjunto integrado de programas para manipulación de datos, cálculo y gráficos.
- El cual fue creado por Ross Ihaka y Robert Gentleman (1996), del Departamento de Estadística de la Universidad de Auckland (Nueva Zelanda).
- Se considera un lenguaje estadístico-matemático que se encuentra en pleno crecimiento..
  - https://jjallaire.shinyapps.io/shiny-crandash/
- Publicado como software libre con licencia GNU-GPL. Garantiza a los usuarios finales la libertad de usar, estudiar, compartir (copiar) y modificar el software.





### Atractivos



- Gran Flexibilidad para combinar diferentes análisis estadísticos, específicos para una situación. Capacidad de manipular y modificar datos, procedimientos y funciones.
- La Comunidad R es muy dinámica (Crecimiento constante de paquetes), integrada por estadísticos de gran renombre. Más de 15 mil paquetes. http://cran.es.r-project.org/web/packages/
- Gráficos de alta calidad (revelaciones de la visualización de datos y producción de gráficas, altamente compatibles con software de edición científicos).
- Rápida implementación de avances metodológicos en estadística.





### Atractivos



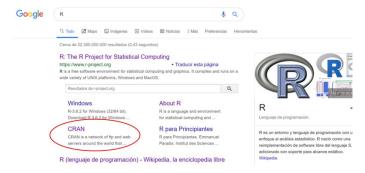
- Libertad de estudiar el funcionamiento del programa y adaptarlo a sus necesidades (Acceso al código fuente).
- Libertad de distribuir copias para ayudar a los demás sin ánimo de lucro.
- Libertad de mejorar el programa y de publicar las mejoras, de modo que toda la comunidad se beneficie (Acceso al Código Fuente)
- Existe un respaldo en recurso de la información en la web.
  - https://www.r-bloggers.com/
  - https://stackoverflow.com/questions/tagged/r
  - Redes sociales: Facebook, Twitter, ..
  - ... la nube en general...







Su búsqueda es sencilla..



O entrando directamente a la página principal de R.

https://cran.r-project.org/







#### Elegir el sistema operativo y seguir los pasos de instalación..



CRAN Mirrors What's new? Task Views

About R R Homepage The R Journal

Software R Sources R Binaries Packages Other

Documentation
Manuals
FAQs
Contributed

#### The Comprehensive R Archive Network

#### Download and Install R

Precompiled binary distributions of the base system and contributed packages, Windows and Mac users most likely want one of these versions of R:

- Download R for Linux
   Download R for (Mac) OS X
- Download R for Windows

  R is part of many Linux distributions, you should check with your Linux package management system in addition to the

link above.

#### Source Code for all Platforms

Windows and Mac users most likely want to download the precompiled binaries listed in the upper box, not the source code. The sources have to be compiled before you can use them. If you do not know what this means, you probably do into want to do it!

- The latest release (2019-12-12, Dark and Stormy Night) R-3.6.2.tar.gz, read what's new in the latest version.
- Sources of R alpha and beta releases (daily snapshots, created only in time periods before a planned release).
- Daily snapshots of current patched and development versions are <u>available here</u>. Please read about <u>new features</u> and <u>bug fixes</u> before filing corresponding feature requests or bug reports.
- · Source code of older versions of R is available here.
- Contributed extension <u>packages</u>

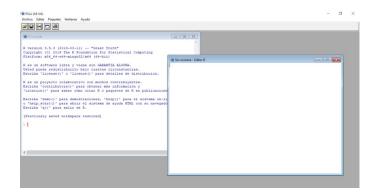
Questions About R







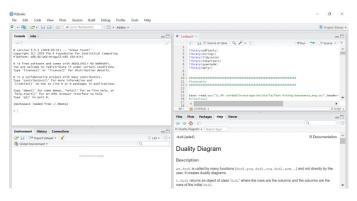
F







#### R-Studio



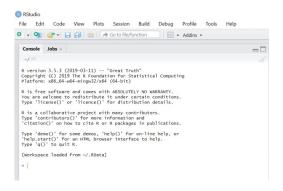
Descargar R-Studio. https://rstudio.com/







#### Consola



#### El prompt:

- "Listo para recibir la siguiente orden"
- + "Hay un proceso en ejecución"







### Reglas sintácticas

- R evalúa expresiones
- El lenguaje es sensible a mayúsculas
- Pueden utilizarse espacios entre elementos de sintaxis a discreción: sin(x+b) es igual que sin(x+b)
- Cada expresión se escribe en al menos una línea
- Dos o más expresiones puede utilizar una línea separándolas por el signo ';'
- En R, donde entra un valor puede entrar una expresión
- Los comentarios se realizan con '#'







Matemáticas	Expresión en R
x = 3	x <- 3
$\sin lpha$	sin( alpha )
$log_{10}(x)$	log( x, 10 )
$v_i$	v[ i ]
$\sum_{i=1}^{n} v_i$	sum( v )



### Trabajar con R



- Limpiar pantalla: Ctrl + L La consola de salida de R trabaja de forma acumulativa, cada nuevo resultado se agrega al cumulo anterior.
- Verificar objetos existentes: ls(), objects()
  Es posible que al dar inicio a una sesión sean cargados objetos previos...es necesario verificar.
- Remover objetos: rm(objeto), rm(list=ls())

  El almacenamiento de objetos innecesarios genera un mayor consumo de memoria y un riesgo de cruce de objetos.
- Asignar directorio: setwd(dir) setwd(Ç:/Users/Mi carpeta/Desktop/Curso R")
  - El directorio base es el lugar donde R lee los archivos de entrada y ubica las salidas dirigidas por defecto.





### Contenido



- 1 Introducción
- 2 Elementos en R
- 3 Objetos en R
- 4 Indexado
- 5 Valores perdidos
- 6 Importar datos en R





### Elementos en R



### Tipos de valores en R

Enteros: 7

■ Reales: 2.5e+11 (2.5 10<sup>11</sup>) Importante! Los decimales se especifican con . y no con ,

Caracter: "papá"

Perdidos: NA

■ No números: NaN (log("papá"))

■ Indeterminaciones  $(-\infty, \infty)$ : - Inf, Inf



## Operadores aritméticos



^	potencia
* /	producto, cociente
+ -	suma, resta
%/%	cociente entero
%%	módulo
:	generar una serie
%*%	producto matricial
()	paréntesis







3 ^ 2







3 ^ 2

[1] 9









- 3 ^ 2
- [1] 9
- 3 ^ 1 + 1
- [1] 4





- 3 ^ 2
- [1] 9
- 3 ^ 1 + 1
- [1] 4
- 3 ^ (1 + 1)
- [1] 9





10 / 2 \* 5





10 / 2 \* 5

[1] 25



10 / 2 \* 5

[1] 25

10 / 2 / 5





10 / 2 \* 5

[1] 25

10 / 2 / 5

[1] 1





10 / 2 \* 5

[1] 25

10 / 2 / 5

[1] 1

21 %% 5





10 / 2 \* 5

[1] 25

10 / 2 / 5

[1] 1

21 %% 5

[1] 1





1:10







1:10

[1] 1 2 3 4 5 6 7 8 9 10





1:10

[1] 1 2 3 4 5 6 7 8 9 10

1:10 \* 2





1:10

[1] 1 2 3 4 5 6 7 8 9 10

1:10 \* 2

[1] 2 4 6 8 10 12 14 16 18 20





1:10

[1] 1 2 3 4 5 6 7 8 9 10

1:10 \* 2

[1] 2 4 6 8 10 12 14 16 18 20

2^(0:8)





1:10

[1] 1 2 3 4 5 6 7 8 9 10

1:10 \* 2

[1] 2 4 6 8 10 12 14 16 18 20

2^(0:8)

[1] 1 2 4 8 16 32 64 128 256





### Operadores lógicos

!	no	
== !=	igual, distinto	
> >=	mayor, mayor o	
	igual	
< <=	menor, menor o	
	igual	
1 11	0	
& &&	У	
#	comentario	









[1] TRUE





[1] TRUE







[1] TRUE

[1] TRUE





[1] TRUE

[1] TRUE

5\*2 > 9 & 3/2 == 1.5





- [1] TRUE
- [1] TRUE

[1] TRUE



### Asignaciones



Variable <- expresión

Variable es un nombre que se utiliza como representación del resultado de una expresión.

- <- Asignar a la izquierda
- -> Asignar a la derecha
- = Asignar a la izquierda





C







a <- 3

[1] 3





[1] 3

C









[1] 3

a





[1] 3

[1] 4

[1] 5



```
r <- 1
area <- pi * (r ^ 2)
longitud <- 2 * pi * r
area
```





```
r <- 1
area <- pi * (r ^ 2)
longitud <- 2 * pi * r
area
```

[1] 3.141593





```
r <- 1
area <- pi * (r ^ 2)
longitud <- 2 * pi * r
area
```

[1] 3.141593

longitud





```
r <- 1
area <- pi * (r ^ 2)
longitud <- 2 * pi * r
area
```

[1] 3.141593

longitud

[1] 6.283185



```
r <- 1:10
```

area <- pi \* (r ^ 2)

2 \* pi \* r -> longitud area

```
r <- 1:10
area <- pi * (r ^ 2)
2 * pi * r -> longitud
area
```

- [1] 3.141593 12.566371 28.274334 50.265482
- [5] 78.539816 113.097336 153.938040 201.061930
- [9] 254.469005 314.159265





- Una función es un procedimiento para realizar una determinada tarea o cálculo
- Función se asocia a un nombre, que sigue las mismas reglas que las variables
- Nombre-de-la-Función( argumento 1, argumento 2, . . .)
- Los argumentos son propios de cada función
- En algunos casos los argumentos tienen valores por defecto





log( 2 )



log( 2 )

[1] 0.6931472

log( 2, 10 )





```
log(2)
[1] 0.6931472
log(2, 10)
[1] 0.30103
```

log( exp( 1 ) )



```
log(2)
[1] 0.6931472
log( 2, 10 )
[1] 0.30103
log( exp( 1 ) )
[1] 1
```





$$log(x = 2, base = 10)$$





$$log(x = 2, base = 10)$$

[1] 0.30103

$$log(base = 10, x = 2)$$





$$log(x = 2, base = 10)$$

[1] 0.30103

$$log(base = 10, x = 2)$$

[1] 0.30103



Función	Acción	
length(obj)	Número de componentes, elementos	
dim(obj)	Dimensión de un objeto	
str(obj)	Estructura de un objeto	
class(obj)	Clase (class) o tipo de objeto	
names(obj)	Nombres de los componentes de un objeto	
c(obj,obj,)	Combina objetos en un vector	
head(obj)	Lista la primera parte de un objeto	
tail(obj)	Lista la última parte (cola) de un objeto	
ls()	Lista los objetos actuales	
rm(obj)	Borra un objeto	
newobj \<- edit(obj)	Edita un objeto y lo guarda	
fix(obj)	Edita sobre un objeto ya creado	







sort()	Ordena un vector
rep()	Generar un conjunto de valores repetidos
seq()	Generar una secuencia numérica
c()	Concatenar los elementos que se indican, separados por comas





round() sqrt() abs()	Redondeo de valores numéricos Raíz cuadrada Valor absoluto
sin() cos()	Función trigonométricas seno Función trigonométricas coseno
log() exp()	Logaritmo natural exponencial $\left(e^{x} ight)$





sum()	Suma los elementos de un vector	
cumsum()	Vector de sumas acumuladas	
max()	Máximo de un vector	
min()	Mínimo de un vector	
t()	Transponer una matriz	
names()	Nombres de filas o columnas	
nrow()	Número de filas	
ncol()	Número de columnas	
rownames()	Nombre de las filas	
<pre>colnames()</pre>	Nombres de las columnas	





str() ls() rm()	Proporciona información sobre la estructura de un objeto Relación de objetos disponibles Elimina uno o varios objetos
read.table()	Carga los datos de un fichero
source()	Carga el código de R escrito en un fichero





#### Funciones estadísticas



Función	lo que hace
mean(x)	Media
median(x)	Mediana
sd(x)	Desviación estándar
var(x)	Varianza
sum(x)	Suma
range(x)	Rango
min(x)	Mínimo
max(x)	Máximo
<pre>scale(x,center=TRUE,scale=TRUE)</pre>	Estandarizar



### Contenido

- 3 Objetos en R



#### Contenido



#### 3 Objetos en R

- Vectores
- Matrices
- Data frames
- Listas
- Factores

### Vectores

- Los vectores son un conjunto ordenado de valores
- Para calcular con todo el vector se emplea el nombre del objeto
- Para utilizar un subconjunto valores se emplea subíndices
- Los subíndices se incluyen entre corchetes ( x [ 3 ] )
- Los subíndices están en el rango: 1 número de elementos del vector
- Los subíndices pueden ser expresiones







```
x <- c( 8, 5, 2, 4, 1, 6, 3 )
length( x )
```

[1] 7

X

[1] 7

X







[1] 7

X

[1] 8 5 2 4 1 6 3

x[]





[1] 7

X

[1] 8 5 2 4 1 6 3

x[]

[1] 8 5 2 4 1 6 3







x[1]







x[1]

[1] 8

x[2:4]



x[1]

[1] 8

x[2:4]

[1] 5 2 4





x[1]

[1] 8

x[2:4]

[1] 5 2 4

x[ c( 3, 5 ) ]



x[1]

[1] 8

x[2:4]

[1] 5 2 4

x[ c( 3, 5 ) ]

[1] 2 1



x[1]

[1] 8

x[2:4]

[1] 5 2 4

x[ c( 3, 5 ) ]

[1] 2 1

x[-1]



x[1]

[1] 8

x[2:4]

[1] 5 2 4

x[ c( 3, 5 ) ]

[1] 2 1

x[-1]

[1] 5 2 4 1 6 3











$$x1 \leftarrow seq(1, 100, by=2)$$

x1

[1] 1 3 5 7 9 11 13 15 17 19 21 23 25 27 29 31 33 35 37 39 41 43 45 47 49 [26] 51 53 55 57 59 61 63 65 67 69 71 73 75 77 79 81 83 85 87 89 91 93 95 97 99







x1

[1] 1 3 5 7 9 11 13 15 17 19 21 23 25 27 29 31 33 35 37 39 41 43 45 47 49 [26] 51 53 55 57 59 61 63 65 67 69 71 73 75 77 79 81 83 85 87 89 91 93 95 97 99

seq(1, 100, length=10)





$$x1 \leftarrow seq(1, 100, by=2)$$

x1

[1] 1 3 5 7 9 11 13 15 17 19 21 23 25 27 29 31 33 35 37 39 41 43 45 47 49 [26] 51 53 55 57 59 61 63 65 67 69 71 73 75 77 79 81 83 85 87 89 91 93 95 97 99

seq(1, 100, length=10)

[1] 1 12 23 34 45 56 67 78 89 100





$$x \leftarrow c(1, 2, 3)$$







$$x \leftarrow c(1, 2, 3)$$

X



$$x \leftarrow c(1, 2, 3)$$

X

### [1] 1 2 3







```
x \leftarrow c(1, 2, 3)
```

[1] 1 2 3

```
x <- seq(1, 100, length=10)
y <- seq(2, 100, length=50)
z <- c(x, y)</pre>
```

Z

```
[1] 1 12 23 34 45 56 67 78 89 100 2 4 6 8 10 12 14 16 18 [20] 20 22 24 26 28 30 32 34 36 38 40 42 44 46 48 50 52 54 56 [39] 58 60 62 64 66 68 70 72 74 76 78 80 82 84 86 88 90 92 94 [58] 96 98 100
```









[1] 2 3 4 5 6



[1] 2 3 4 5 6





[1] 2 3 4 5 6

2 4 6 8 10 7 9 11 13 15





[1] 2 3 4 5 6

2 4 6 8 10 7 9 11 13 15

Función **which** devuelve la posición de los elementos que cumplen la condición.







[1] 2 3 4 5 6

2 4 6 8 10 7 9 11 13 15

Función **which** devuelve la posición de los elementos que cumplen la condición.

[1] 8 9 10







Es posible crear vectores de caracteres, los cuales también son utilizadas en R, para etiquetar gráficos. Una cadena de caracteres se construye escribiendo entre comillas la sucesión de caracteres que la define, por ejemplo

```
y <- c("Bogota", "Cali", "Medellin", "Cartagena", "Barranquilla")
```





Es posible crear vectores de caracteres, los cuales también son utilizadas en R, para etiquetar gráficos. Una cadena de caracteres se construye escribiendo entre comillas la sucesión de caracteres que la define, por ejemplo

```
y <- c("Bogota", "Cali", "Medellin", "Cartagena", "Barranquilla")
```

```
[1] "Bogota" "Cali" "Medellin" "Cartagena" "Barranquilla"
```





La función **paste()** une todos los vectores que se suministran y construye una sola cadena de caracteres

```
y <- c("Bogota", "Cali", "Medellin", "Cartagena", "Barranquilla")
w <- c("Muy malo", "Malo", "Regular", "Bueno", "Muy bueno")
paste(y, w, sep=" ")</pre>
```





La función **paste()** une todos los vectores que se suministran y construye una sola cadena de caracteres

```
y <- c("Bogota", "Cali", "Medellin", "Cartagena", "Barranquilla")
w <- c("Muy malo", "Malo", "Regular", "Bueno", "Muy bueno")
paste(y, w, sep=" ")
```

- [1] "Bogota Muy malo" "Cali Malo" "Medellin Regular"
- [4] "Cartagena Bueno" "Barranquilla Muy bueno"



### Ejercicio 1.



- 1. Calcula la suma de 25 y 75 (+)
- 2. Calcula la raíz cuadrada de 25 (sqrt)
- 3. Crea una secuencia del 1 al 15 (:)
- 4. Crea una secuencia del 1 al 20 de 2 en 2 (seq)
- 5. Repite la secuencia anterior 3 veces (rep)
- 6. Crea un vector de longitud 5 y calcula su media (c, mean)
- 7. Súmale a todos los componentes de ese vector 3 y calcula su media (+, mean)
- 8. Crea un vector de longitud 5 con una posición vacía y calcula su media (c, NA, mean)



## Ejercicio 2.



- 1. Genere el siguiente vector de edades Edad<- c(25, 30, 22, 26, 32, 25, 21, 29, 34, 37, 30, 28, 41, 22)
- 2. Genere un vector de los nombres de los funcionarios. Asigne los nombres a las edades (names())

  Pedro James Miguel Daniel Jose Diana Sandra Adriana Alexis Claudia

Pedro, James, Miguel, Daniel, Jose, Diana, Sandra, Adriana, Alexis, Claudia, Ana, Andrea, Jorge, Carlos

- 3. Identifique cuales son los nombres de los empleados con edades menores 25 ¿Como lo haría en R? (which())
- 4. Cree un objeto que junte el vector Edad con Nombres. De tal forma que se vizualice lo siguiente: (paste())
- "Pedro tiene 25 años"



### Contenido



### 3 Objetos en R

- Vectores
- Matrices
- Data frames
- Listas
- Factores

### Matrices



- Una matriz es un conjunto ordenado de vectores
- Los elementos de la matriz están ordenados por filas y columnas
- Todos los vectores son del mismo tipo: enteros, caracteres, ...
- Los elementos de una matriz se identifican por dos subíndices
- El uso de los subíndices sigue las mismas reglas que en el caso de los vectores
- Se puede crear uniendo vectores o mediante la función matrix()



```
m <- matrix(1:12, 4, 3)
```







```
m <- matrix(1:12, 4, 3)
m
```

### Contenido



- 3 Objetos en R
  - Vectores
  - Matrices
  - Data frames
  - Listas
  - Factores

#### Data frames



- Son semejantes a las matrices
- Se organizan por filas y columnas
- Las columnas no tienen por que ser homogéneas
- Las columnas tienen nombre
- Habitualmente los data frames se obtienen de la lectura de un fichero de datos





cars





#### cars

. . .

speed	dist	
1	4	2
2	4	10
3	7	4
4	7	22
5	8	16
6	9	10
7	10	18
8 1	10	26
9 1	10	34
10 1	11	17
11 1	11	28





dim(cars)



#### dim(cars)

[1] 50 2



dim(cars)

[1] 50 2

head(cars)



#### dim(cars)

[1] 50 2

#### head(cars)

### 





#### Función cbind

```
z <- 1:10
y <- 1:10
x <- 1:10
M <- cbind(x, y, z)
```





#### Función cbind

```
z <- 1:10
y <- 1:10
x <- 1:10
M <- cbind(x, y, z)
```

```
[1,] 1 1 1 1 [2,] 2 2 2 [3,] 3 3 3 [4,] 4 4 4 4 [5,] 5 5 5 [6,] 6 6 6 6 [7,] 7 7 7 [8,] 8 8 8 [9,] 9 9 9 [10,] 10 10 10
```





#### Función rbind

Μ



#### Función rbind

```
[,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] x 1 2 3 4 5 6 7 8 9 10 y 1 2 3 4 5 6 7 8 9 10 z 1 2 3 4 5 6 7 8 9 10
```

#### Data frames



#### **Datasets**

Así como la base utilizada *(cars)*, existen múltiples datasets preinstalados en R y se puede acceder a ellos directamente o mediante librerías.

En el siguiente link encontrará la descripción de los datasets.

https://stat.ethz.ch/R-manual/R-devel/library/datasets/html/00Index.html

### Contenido



#### 3 Objetos en R

- Vectores
- Matrices
- Data frames
- Listas
- Factores

#### Listas

Son objetos que pueden contener conjuntos heterogéneos de objetos:

- valores
- vectores
- matrices
- data frames
- listas

Se suelen encontrar como resultado de funciones













```
$a
[1] 1 3 5
$b
[1] "l" "p" "r" "s"
$c
[1] 3
```





```
$a
[1] 1 3 5
$b
[1] "l" "p" "r" "s"
$c
[1] 3
```

class(lista)





```
$a
[1] 1 3 5
$b
[1] "l" "p" "r" "s"
$c
[1] 3
```

#### class(lista)

```
[1] "list"
```



### Contenido



#### 3 Objetos en R

- Vectores
- Matrices
- Data frames
- Listas
- Factores





Hay variables codificadas, ejemplo sexo, donde 1 es "Masculino" y 2 "Femenino", que en realidad tiene un carácter *cualitativo* o *categórico*.

```
sexo <- c(1, 1, 1, 1, 2, 2, 2)
peso <- c(60, 65, 70, 66, 80, 60, 76)
df <- data.frame(sexo, peso)
df$sexo <- factor(df$sexo)
df</pre>
```



Hay variables codificadas, ejemplo sexo, donde 1 es "Masculino" y 2 "Femenino", que en realidad tiene un carácter *cualitativo* o *categórico*.

```
sexo <- c(1, 1, 1, 1, 2, 2, 2)
peso <- c(60, 65, 70, 66, 80, 60, 76)
df <- data.frame(sexo, peso)
df$sexo <- factor(df$sexo)
df</pre>
```







#### Creamos las etiquetas





#### Creamos las etiquetas

```
sexo peso
1 masculino 60
2 masculino 65
3 masculino 66
4 masculino 66
5 femenino 80
6 femenino 60
```

### Contenido



- 1 Introducción
- 2 Elementos en R
- 3 Objetos en R
- 4 Indexado
- 5 Valores perdidos
- 6 Importar datos en R



### Contenido



#### 4 Indexado

- Condiciones lógicas
- Vectores
- Matrices
- Listas
- Data frame





$$x \leftarrow seq(-1, 1, .1)$$

-





$$x \leftarrow seq(-1, 1, .1)$$

X





$$x \leftarrow seq(-1, 1, .1)$$

X

x < 0



$$x \leftarrow seq(-1, 1, .1)$$

X

x < 0

- [13] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE







$$x \leftarrow seq(-1, 1, .1)$$

X

x < 0

- [13] FALSE FALSE FALSE FALSE FALSE FALSE FALSE

$$x >= 0$$





$$x \leftarrow seq(-1, 1, .1)$$

X

- [1] -1.0 -0.9 -0.8 -0.7 -0.6 -0.5 -0.4 -0.3 -0.2 -0.1 0.0 0.1 0.2 0.3 0.4 [16] 0.5 0.6 0.7 0.8 0.9 1.0
- x < 0
- [13] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE

$$x >= 0$$

- [1] FALSE TRUE FALSE
- [13] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE





cond <- 
$$(x > 0)$$
 &  $(x < .5)$  cond





## Condiciones lógicas múltiples



cond <- 
$$(x > 0)$$
 &  $(x < .5)$  cond

- [1] FALSE TRUE
- [13] TRUE TRUE TRUE FALSE FALSE FALSE FALSE FALSE



### Condiciones lógicas múltiples



cond <- 
$$(x > 0) & (x < .5)$$
 cond

[1] FALSE TRUE
[13] TRUE TRUE TRUE FALSE FALSE FALSE FALSE FALSE FALSE

cond <- 
$$(x >= .5) | (x <= -.5)$$
 cond



### Condiciones lógicas múltiples

cond <- 
$$(x > 0) & (x < .5)$$
 cond

- [1] FALSE FA
- [13] TRUE TRUE TRUE FALSE FALSE FALSE FALSE FALSE

cond <- 
$$(x >= .5) | (x <= -.5)$$

- [1] TRUE TRUE TRUE TRUE TRUE TRUE FALSE FALSE FALSE FALSE FALSE
- [13] FALSE FALSE FALSE TRUE TRUE TRUE TRUE TRUE TRUE







sum(cond)





sum(cond)

[1] 12







sum(cond)

[1] 12

sum(!cond)





```
sum(cond)
```

[1] 12

sum(!cond)

[1] 9





```
sum(cond)
```

[1] 12

sum(!cond)

[1] 9

as.numeric(cond)





```
sum (cond)
```

[1] 12

sum(!cond)

[1] 9

as.numeric(cond)





### Contenido



#### 4 Indexado

- Condiciones lógicas
- Vectores
- Matrices
- Listas
- Data frame





$$x \leftarrow seq(1, 100, 2)$$

X





$$x \leftarrow seq(1, 100, 2)$$

X

[1] 1 3 5 7 9 11 13 15 17 19 21 23 25 27 29 31 33 35 37 39 41 43 45 47 49 [26] 51 53 55 57 59 61 63 65 67 69 71 73 75 77 79 81 83 85 87 89 91 93 95 97 99





$$x \leftarrow seq(1, 100, 2)$$

X

[1] 1 3 5 7 9 11 13 15 17 19 21 23 25 27 29 31 33 35 37 39 41 43 45 47 49 [26] 51 53 55 57 59 61 63 65 67 69 71 73 75 77 79 81 83 85 87 89 91 93 95 97 99

x[x > 20]





$$x \leftarrow seq(1, 100, 2)$$

X

[1] 21 23 25 27 29 31 33 35 37 39 41 43 45 47 49 51 53 55 57 59 61 63 65 67 69 [26] 71 73 75 77 79 81 83 85 87 89 91 93 95 97 99







$$z \leftarrow seq(-10, 10, by = .5)$$



$$z \leftarrow seq(-10, 10, by = .5)$$

- [1] -10.0 -9.5 -9.0 -8.5 -8.0 -7.5 -7.0 -6.5 -6.0 -5.5 -5.0 -4.5
- [13] -4.0 -3.5 -3.0 -2.5 -2.0 -1.5 -1.0 -0.5 0.0 0.5 1.0 1.5
- [25] 2.0 2.5 3.0 3.5 4.0 4.5 5.0 5.5 6.0 6.5 7.0 7.5
- [37] 8.0 8.5 9.0 9.5 10.0





$$z \leftarrow seq(-10, 10, by = .5)$$

$$z[z < -5 | z > 5]$$





$$z \leftarrow seq(-10, 10, by = .5)$$

- [1] -10.0 -9.5 -9.0 -8.5 -8.0 -7.5 -7.0 -6.5 -6.0 -5.5 -5.0 -4.5
- [13] -4.0 -3.5 -3.0 -2.5 -2.0 -1.5 -1.0 -0.5 0.0 0.5 1.0 1.5
- [25] 2.0 2.5 3.0 3.5 4.0 4.5 5.0 5.5 6.0 6.5 7.0 7.5
- [37] 8.0 8.5 9.0 9.5 10.0

$$z[z < -5 | z > 5]$$

- [1] -10.0 -9.5 -9.0 -8.5 -8.0 -7.5 -7.0 -6.5 -6.0 -5.5 5.5 6.0
- [13] 6.5 7.0 7.5 8.0 8.5 9.0 9.5 10.0





$$z \leftarrow seq(-10, 10, by = .5)$$

Z

- [1] -10.0 -9.5 -9.0 -8.5 -8.0 -7.5 -7.0 -6.5 -6.0 -5.5 -5.0 -4.5
- [13] -4.0 -3.5 -3.0 -2.5 -2.0 -1.5 -1.0 -0.5 0.0 0.5 1.0 1.5
- [25] 2.0 2.5 3.0 3.5 4.0 4.5 5.0 5.5 6.0 6.5 7.0 7.5
- [37] 8.0 8.5 9.0 9.5 10.0

$$z[z < -5 | z > 5]$$

- [1] -10.0 -9.5 -9.0 -8.5 -8.0 -7.5 -7.0 -6.5 -6.0 -5.5 5.5 6.0
- [13] 6.5 7.0 7.5 8.0 8.5 9.0 9.5 10.0

cond <- (
$$z >= 0 & z <= 5$$
)

z[cond]







$$z \leftarrow seq(-10, 10, by = .5)$$

Z

- [1] -10.0 -9.5 -9.0 -8.5 -8.0 -7.5 -7.0 -6.5 -6.0 -5.5 -5.0 -4.5
- [13] -4.0 -3.5 -3.0 -2.5 -2.0 -1.5 -1.0 -0.5 0.0 0.5 1.0 1.5
- [25] 2.0 2.5 3.0 3.5 4.0 4.5 5.0 5.5 6.0 6.5 7.0 7.5
- [37] 8.0 8.5 9.0 9.5 10.0

$$z[z < -5 | z > 5]$$

- [1] -10.0 -9.5 -9.0 -8.5 -8.0 -7.5 -7.0 -6.5 -6.0 -5.5 5.5 6.0
- [13] 6.5 7.0 7.5 8.0 8.5 9.0 9.5 10.0

cond <- (
$$z >= 0 & z <= 5$$
)

z[cond]

 $[1] \ 0.0 \ 0.5 \ 1.0 \ 1.5 \ 2.0 \ 2.5 \ 3.0 \ 3.5 \ 4.0 \ 4.5 \ 5.0 \\$ 





### Contenido



#### 4 Indexado

- Condiciones lógicas
- Vectores
- Matrices
- Listas
- Data frame



```
m <- matrix( 1:12, 4, 3 )
```







```
m <- matrix( 1:12, 4, 3 )
```

```
[,1] [,2] [,3]
[1,] 1 5 9
[2,] 2 6 10
[3,] 3 7 11
[4,] 4 8 12
```





```
m <- matrix( 1:12, 4, 3 )
m
```

[,1] [,2] [,3] [1,] 1 5 9 [2,] 2 6 10 [3,] 3 7 11 [4,] 4 8 12





```
m <- matrix(1:12, 4, 3)
m
```





```
m <- matrix( 1:12, 4, 3 )
m
```

m[1,]

[1] 1 5 9

m[3:4,2:3]





```
m <- matrix(1:12, 4, 3)
m
```

```
[1,1] [,2]
[1,] 7 11
[2,] 8 12
```





m[-1,]





#### m[-1,]

[,1] [,2] [,3] [1,] 2 6 10 [2,] 3 7 11 [3,] 4 8 12









#### m[-1,]

- [,1] [,2] [,3] [1,] 2 6 10 [2,] 3 7 11 [3,] 4 8 12
- m[2,3]<-"Cali"

```
[,1] [,2] [,3] [1,] "1" "5" "9" [2,] "2" "6" "Cali" [3,] "3" "7" "11" [4,] "4" "8" "12"
```





#### m[-1,]

- [1,] [,2] [,3] [1,] 2 6 10 [2,] 3 7 11 [3,] 4 8 12
- m[2,3]<-"Cali"

```
[,1] [,2] [,3] [1,] "1" "5" "9" [2,] "2" "6" "Cali" [3,] "3" "7" "11" [4,] "4" "8" "12"
```

class(m)





#### m[-1,]

- [,1] [,2] [,3] [1,] 2 6 10 [2,] 3 7 11 [3,] 4 8 12
- m[2,3]<-"Cali"

```
[,1] [,2] [,3] [1,] "1" "5" "9" [2,] "2" "6" "Cali" [3,] "3" "7" "11" [4,] "4" "8" "12"
```

#### class(m)

[1] "matrix"



#### m[-1,]

- [,1] [,2] [,3] [1,] 2 6 10 [2,] 3 7 11 [3,] 4 8 12
- m[2,3]<-"Cali"

```
[,1] [,2] [,3]
[1,] "1" "5" "9"
[2,] "2" "6" "Cali"
[3,] "3" "7" "11"
[4,] "4" "8" "12"
```

#### class(m)

[1] "matrix"

str(m)





#### m[-1,]

```
[,1] [,2] [,3]
[1,] 2 6 10
[2,] 3 7 11
[3,] 4 8 12
```

#### m[2,3]<-"Cali"

```
[,1] [,2] [,3]
[1,] "1" "5" "9"
[2,] "2" "6" "Cali"
[3,] "3" "7" "11"
[4,] "4" "8" "12"
```

#### class(m)

[1] "matrix"

#### str(m)

chr [1:4, 1:3] "1" "2" "3" "4" "5" "6" "7" "8" "9" "Cali" "11" "12"



### Ejercicio 3.



- 1. Los siguientes valores (50, 70, 130, 40, 100, 70, 140, 30, 110) corresponden al precio de licores (xbotella) en discotecas de Cali, clasificados por licores (columnas: Blanco, Caldas, Márquez) (colnames()) y discotecas (filas: Living, Pérgola, Caderona) (rownames())
- **2.** Se solicita anexar en la matriz los precios de las discotecas: Lolas(120,130,140) y Urbano(80, 100,120).
- **3.** Además se solicita anexar el valor de la cerveza "corona" la cuál es muy vendida en dichas discotecas: (20,15,25,17,22)
- 4. Seleccione todos los precios de la discoteca Lolas
- 5. Identifique cual es la discoteca con precios más altos en licor Márquez
- Identifique cuales son las discotecas con precios más altos en Blanco y Corona





#### Contenido



#### 4 Indexado

- Condiciones lógicas
- Vectores
- Matrices
- Listas
- Data frame





length(lista)



## Indexado en listas



#### length(lista)

[1] 3



## Indexado en listas



length(lista)

[1] 3

lista**\$**b





#### length(lista)

[1] 3

lista**\$**b



# Indexado en listas



#### length(lista)

[1] 3

lista**\$**b

lista\$b[3]





#### length(lista)

[1] 3

#### lista**\$**b

#### lista\$b[3]



# Indexado en listas



#### length(lista)

[1] 3

lista**\$**b

lista\$b[3]

[1] "r"

lista[[2]][3]



## Indexado en listas



#### length(lista)

[1] 3

#### lista**\$**b

[1] "l" "p" "r" "s"

#### lista\$b[3]

[1] "r"

### lista[[2]][3]

[1] "r"



### Contenido



#### 4 Indexado

- Condiciones lógicas
- Vectores
- Matrices
- Listas
- Data frame





cars[ ,2]





cars[ ,2]

[1] [21] [41] 93 120 





#### cars[ ,2]

```
[1]
          10
                            10
                                             17
                                     26
[21]
      36
                   20
                       26
                            54
                                32
                                     40
                                         32
                                             40
                                                 50
                                                      42
                                                                   84
                                                                        36
         60
              80
                                                          56
                                                               76
                                                                                         48
[41]
          56
                   66
                       54
                            70
                                92
                                     93 120
                                             85
```

cars\$dist



#### cars[ ,2]

```
[1]
                        16
                             10
          10
                                 18
                                      26
                                           34
                                               17
                                                    28
                                                        14
[21]
      36
                    20
                        26
                             54
                                 32
                                      40
                                          32
                                               40
                                                    50
                                                        42
                                                             56
                                                                      84
                                                                           36
          60
               80
                                                                 76
                                                                               46
                                                                                             48
                        54
[41]
          56
                    66
                             70
                                 92
                                      93 120
                                               85
```

#### cars\$dist

```
[1]
           10
                               10
                                                  17
[21]
      36
           60
                     20
                          26
                               54
                                   32
                                             32
                                                  40
                                                       50
                                                           42
                                                                56
                                                                     76
                                                                               36
                                                                                        68
                                                                                                  48
                                                  85
```

[41] 

cars[ ,"dist"]





#### cars[ ,2]

```
[1]
                             10
           10
                                      26
                                           34
                                                17
[21]
                    20
                         26
                             54
                                      40
                                           32
                                                    50
                                                         42
                                                                       84
      36
           60
               80
                                  32
                                                40
                                                              56
                                                                  76
                                                                            36
                                                                                46
[41]
           56
                    66
                         54
                             70
                                  92
                                      93 120
                                                85
```

#### cars\$dist

```
[1]
           10
                               10
                                                  17
[21]
      36
                     20
                          26
                               54
                                    32
                                                  40
                                                       50
                                                            42
                                                                      76
                                                                               36
                                                                                                   48
                                                  85
```

[41] 

#### cars[ ,"dist"]

[1]	2	10	4	22	16	10	18	26	34	17	28	14	20	24	28	26	34	34	46	26
[21]	36	60	80	20	26	54	32	40	32	40	50	42	56	76	84	36	46	68	32	48

[41] 70 92 93 120 85







cars[ 3, ]





```
cars[ 3, ]
```





```
cars[ 3, ]
```

speed dist 3 7 4

cars[3,2]





```
speed dist
```

[1] 4

cars[3,2]









```
1 1 1.78139992 0
2 2 1.32193053 0
3 3 1.14856140 0
4 4 -1.26046862 0
5 5 0.52795348 0
6 1 0.86030751 0
7 2 -0.03876488 0
8 3 -1.31705080 0
9 4 0.46210892 0
10 5 0.74472228 0
```

y z





df[df\$y > 0,]





#### df [df\$y > 0,]

- yz 1 1 1.8027998 0 4 4 1.2014048 0 6 1 0.3066946 0 7 2 0.3458662 0 8 3 1.9886410 0
- 9 4 0.2423531 0

#### df[df\$y > 0,]

```
y z
1 1 1.8027998 0
4 4 1.2014048 0
6 1 0.3066946 0
7 2 0.3458662 0
8 3 1.9886410 0
9 4 0.2423531 0
```

La función subset simplifica el código.

#### df[df\$y > 0,]

```
V Z
1 1 1.8027998 0
4 4 1.2014048 0
6 1 0.3066946 0
7 2 0 3458662 0
8 3 1.9886410 0
9 4 0.2423531 0
```

La función subset simplifica el código.

#### subset(df, y > 0)

y z

```
1 1 1.8027998 0
4 4 1.2014048 0
6 1 0.3066946 0
7 2 0.3458662 0
8 3 1.9886410 0
9 4 0.2423531 0
```





#### Generemos el siguiente data.frame

```
id <- c( 1:5 )
date <- c( "10/07/08", "10/08/08", "10/09/08", "10/10/08", "10/11/08" )
country <- c( "US", "US", "UK", "UK", "UK" )
gender <- c( "M", "F", "F", NA, "F" )
age <- c( NA, 45, 25, 39, 99 )
q1 <- c( 5, 3, 3, 3, 2 )
q2 <- c( 5, 5, 5, NA, 2 )
q3 <- c( 5, 5, 2, NA, 1 )
df <- data.frame( id, date, country, gender, age, q1, q2, q3,
stringsAsFactors = FALSE )</pre>
```

df





#### Generemos el siguiente data.frame

```
id <- c( 1:5 )
date <- c( "10/07/08", "10/08/08", "10/09/08", "10/10/08", "10/11/08" )
country <- c( "US", "US", "UK", "UK", "UK" )
gender <- c( "M", "F", "F", NA, "F" )
age <- c( NA, 45, 25, 39, 99 )
q1 <- c( 5, 3, 3, 3, 2 )
q2 <- c( 5, 5, 5, NA, 2 )
q3 <- c( 5, 5, 2, NA, 1 )
df <- data.frame( id, date, country, gender, age, q1, q2, q3,
stringsAsFactors = FALSE )</pre>
```

#### df

```
id date country gender age q1 q2 q3 1 1 10/07/08 US M NA 5 5 5 5 2 2 10/08/08 US F 45 3 5 5 3 3 10/09/08 UK F 25 3 5 2 4 4 10/10/08 UK <NA> 39 3 NA NA 5 5 10/11/08 UK F 99 2 2 1
```





# Ejercicio 4.



Con el objeto creado anteriormente df

- Crea un nuevo data frame que incluya únicamente las variables q1, q2 y q3.
- Crea de dos formas un nuevo data frame que incluya el país al que pertenecen los sujetos (con el nombre y con el índice)
- 3 Crea un nuevo data frame eliminando las variables q2 y q3
- 4 Selecciona las 3 primeras filas
- 5 ¿Cómo escribirías la condición de ser mujer y de UK?
- 6 Selecciona las observaciones que cumplan dicha condición







df\$nueva <- df\$q1 \* 2 df





## Crear una nueva variable en un data.frame



```
df$nueva <- df$q1 * 2
df</pre>
```

```
date country gender age q1 q2 q3 nueva
id
1 10/07/08
              US
                        NΑ
                                     10
2 10/08/08
              US
                        45 3 5 5
3 10/09/08
          UK
                        25 3
4 10/10/08 UK
                   <NA>
                        39 3 NA NA
5 10/11/08
          UK
```



# Crear una nueva variable en un data.frame

```
4
```

```
df$agecat[ df$age > 75 ] <- "anciano" # crea la variable
df$agecat[ df$age <= 75 & df$age > 44 ] <- "maduro"
df$agecat[ df$age <= 44 ] <- "joven"
df</pre>
```



### Crear una nueva variable en un data.frame

```
df$agecat[ df$age > 75 ] <- "anciano" # crea la variable
df$agecat[ df$age <= 75 & df$age > 44 ] <- "maduro"
df$agecat[ df$age <= 44 ] <- "joven"
df</pre>
```

```
id date country gender age q1 q2 q3 nueva agecat
1 1 10/07/08 US M NA 5 5 5 10 <NA>
2 2 10/08/08 US F 45 3 5 5 6 maduro
3 3 10/09/08 UK F 25 3 5 2 6 joven
4 4 10/10/08 UK NA> 39 3 NA NA 6 joven
5 5 10/11/08 UK F 99 2 2 1 4 anciano
```



# Renombrar variables



names( df )

# Renombrar variables



#### names( df )

```
[1] "id" "date" "country" "gender" "age" "q1" "q2"
```

[8] "q3" "nueva" "agecat"



## Renombrar variables



```
names( df )
[1] "id" "date" "country" "gender" "age" "q1" "q2"
[8] "q3" "nueva" "agecat"

names( df )[ 1 ] <- "ID"
names( df )[ 3 ] <- "pais"
names( df )[ 4 ] <- "G"
names( df )[ 6:8 ] <- c( "it1", "it2", "it3" )
df</pre>
```



names( df )

### Renombrar variables



```
[1] "id" "date" "country" "gender" "age" "q1" "q2"
[8] "q3" "nueva" "agecat"

names( df )[ 1 ] <- "ID"
names( df )[ 3 ] <- "pais"
names( df )[ 4 ] <- "G"
names( df )[ 6:8 ] <- c( "it1", "it2", "it3" )
df
```

```
TD date pais G age it1 it2 it3 nueva agecat
1 1 10/07/08 US M NA 5 5 5 5 10 <NA>
2 2 10/08/08 US F 45 3 5 5 6 maduro
3 3 10/09/08 UK F 25 3 5 2 6 joven
4 4 10/10/08 UK <NA> 39 3 NA NA 6 joven
5 5 10/11/08 UK F 99 2 2 1 4 anciano
```

# Contenido

- 5 Valores perdidos

# Valores perdidos

- Valores imposibles: NaN (Not a Number)
- Los valores perdidos: NA (Not available)

Hay muchas funciones para identificar estos valores: is.na()

### Valores perdidos

```
y <- c(1, 2, 3, NA) is.na(y)
```



## Valores perdidos

[1] FALSE FALSE FALSE TRUE



```
y <- c( 1, 2, 3, NA ) is.na( y )
```

[1] FALSE FALSE FALSE TRUE



#### Valores perdidos



```
y \leftarrow c(1, 2, 3, NA)
is.na( y )
```

[1] FALSE FALSE FALSE TRUE

```
is.na( df[ , 4:10 ] )
```

```
age
              it1 it2 it3 nueva agecat
[1.] FALSE TRUE FALSE FALSE FALSE
                                     TRUE
[2,] FALSE FALSE FALSE FALSE FALSE
                                   FALSE
[3,] FALSE FALSE FALSE FALSE FALSE FALSE
[4.] TRUE FALSE FALSE TRUE
                         TRUE FALSE FALSE
[5,] FALSE FALSE FALSE FALSE FALSE FALSE
```





df\$age[ is.na( df\$age ) ] <- 9999





```
df$age[ is.na( df$age ) ] <- 9999</pre>
```

```
ID
      date pais
                    age it1 it2 it3 nueva
                                         agecat
1 10/07/08
            US
                 M 9999
                                      10
                                           <NA>
2 10/08/08 US
                                         maduro
                   25 3 5 2
3 10/09/08 UK
                                         joven
4 10/10/08 UK <NA>
                   39 3 NA
                                         joven
5 10/11/08 UK
                                      4 anciano
                     99
```





#### df\$age[ is.na( df\$age ) ] <- 9999</pre>

```
ID
       date pais G age it1 it2 it3 nueva
                                       agecat
  1 10/07/08
            US
                 M 9999
                                    10
                                         <NA>
  2 10/08/08 US
                                       maduro
 3 10/09/08 UK
                 F 25 3 5 2 6
                                      ioven
 4 10/10/08 UK <NA> 39 3 NA NA 6
                                       joven
5 5 10/11/08 UK
                 F 99 2
                                     4 anciano
```

#### Excluir NA del análisis





#### df\$age[ is.na( df\$age ) ] <- 9999</pre>

```
ID
       date pais G age it1 it2 it3 nueva
                                       agecat
  1 10/07/08
            US
                 M 9999
                                    10
                                         <NA>
  2 10/08/08 US
                                       maduro
                 F 25 3 5 2 6
 3 10/09/08 UK
                                      ioven
 4 10/10/08 UK <NA> 39 3 NA NA 6
                                       joven
5 5 10/11/08 UK
                   99 2
                                     4 anciano
```

#### Excluir NA del análisis

[1] NA





```
df$age[ is.na( df$age ) ] <- 9999</pre>
```

#### Excluir NA del análisis

[1] NA







```
df$age[ is.na( df$age ) ] <- 9999
```

#### Excluir NA del análisis

[1] NA

[1] 6



## na.omit()

na.omit() que elimina cualquier fila de un dataframe que tenga valores faltantes.

```
df <- na.omit( df )</pre>
df
```



#### na.omit()



na.omit() que elimina cualquier fila de un dataframe que tenga valores faltantes.

```
df <- na.omit( df )
df
```

```
TD date pais G age it1 it2 it3 nueva agecat 2 2 10/08/08 US F 45 3 5 5 6 maduro 3 3 10/09/08 UK F 25 3 5 2 6 joven 5 5 10/11/08 UK F 99 2 2 1 4 anciano
```





lógico	convierte
is.numeric()	as.numeric()
<pre>is.character()</pre>	as.character()
is.vector()	as.vector()
<pre>is.matrix()</pre>	<pre>as.matrix()</pre>
<pre>is.data.frame()</pre>	as.data.frame()

```
a <- c( 1, 2, 3 ) is.numeric( a )
```







lógico	convierte
is.numeric()	as.numeric()
<pre>is.character()</pre>	as.character()
<pre>is.vector()</pre>	as.vector()
<pre>is.matrix()</pre>	as.matrix()
<pre>is.data.frame()</pre>	as.data.frame()

```
a <- c( 1, 2, 3 ) is.numeric( a )
```

[1] TRUE





lógico	convierte
is.numeric()	as.numeric()
<pre>is.character()</pre>	as.character()
is.vector()	as.vector()
<pre>is.matrix()</pre>	<pre>as.matrix()</pre>
is.data.frame()	as.data.frame()

```
a <- c(1, 2, 3)
is.numeric(a)

[1] TRUE

b <- as.character(a)</pre>
```





lógico	convierte
is.numeric()	as.numeric()
is.character()	as.character()
is.vector()	as.vector()
is.matrix()	<pre>as.matrix()</pre>
is.data.frame()	as.data.frame()

```
a <- c( 1, 2, 3 )
is.numeric( a )
```

[1] TRUE

```
b <- as.character(a)
b
```

```
[1] "1" "2" "3"
```



#### Contenido



- 1 Introducción
- 2 Elementos en R
- 3 Objetos en R
- 4 Indexado
- 5 Valores perdidos
- 6 Importar datos en R





Algunas consideraciones para importar datos

- La función read.table()
- Función read.csv()
- Library(foreign) ## importa datos de spss, minitab, stata, etc
- Guardar datos en el directorio: función write.table() , write.csv()





#### Antes de importar un archivo se debe comprobar:

- 1 La ruta o directorio donde reposa el archivo.
- 2 Identificar el nombre del archivo.
- 3 Identificar la extensión o formato del archivo a importar: .xls, .xlsx, .txt, .csv, .sav, .mpj
- 4 Las columnas y las filas son consistentes, es decir, no tener celdas combinadas de Excel, filas o columnas en blanco.
- 5 Si las columnas o filas están etiquetadas, que no haya símbolos extraños, por preferencia omitir: \$, Ñ, %, ' (tildes).
- 6 Si hay datos perdidos, que su codificación sea consistente: NA.







La función más importante para importar datos: read.table() automáticamente convierte los datos en un dataframe.

```
df <- read.table(file,
header = valor_logico,
sep = "delimitador",
dec = "signo del decimal")</pre>
```

```
- header TRUE/FALSE según la primera fila del fichero
```

- sep es el delimitador: el separador de campos + sep = ";", sep=".", sep=",",sep="\t" . .
- dec es el indicador del signo decimal + dec=".", dec=";". . .

Si el conjunto de datos se encuentra en el directorio de trabajo. Entonces Ej:

```
df<-read.table("Datos1.txt",header=T, sep="",dec=".")</pre>
```



### Ejemplo



Lea el conjunto de datos en el archivo Base-1. Tenga en cuenta:

- El directorio
- La extensión del documento
- El separador
- El símbolo de decimales
- La cabecera (primera fila)

```
setwd("G:/Mi unidad/Clases/Univalle/2020-1/Clase 1/")
read.table("Base_1.csv",header=TRUE, sep=";",dec=",")
```

También puede utilizar funciones como read.csv()



### Ejercicio 5



- Guarda la base importada con el nombre "PibEsp"
- Selecciona el valor total del PIB para Andalucía
- Selecciona el valor del PIB en Andalucía correspondiente a la agricultura
- Calcula el promedio de PIB por cada ciudad. ¿Quién tiene el mayor PIB?
- Explore la función aggregate() con la ayuda de R, Nos puede ayudar en algo?
- 6 Utilice la función aggregate(), guarde el data.frame y renombre las columnas del data.frame
- Explore la función boxplot() con la ayuda de R, Nos puede ayudar en algo?
- Realice digramas de caja (boxplot) del PIB por cada ciudad en un solo gráfico
- Guarde el data.frame del punto 6. con la función write.table()







Una forma sencilla de cargar un conjunto de datos es mediante la opción de copiar y pegar, sin embargo para que R asimile dicha información es necesario ejecutar un comando.

```
datos <- read.delim("clipboard")
datos</pre>
```





Existe un paquete clasificado como "paquete recomendado" que permite una comunicación fluida entre programas para el análisis de datos; foreign().

El paquete foreign incorpora varias funciones para la lectura de datos provenientes de SPSS (.sav formato), SAS, Epi-Infor (.rec), Stata (.dta), Minitab ()

A veces los archivos provenientes de Stata tienen problemas por la versión del mismo. Recomiendo diferentes paquetes como

- read.dta13() de la librería readstata13
- read\_dta() de la librería haven
- read.spss() de la librería foreign para archivos de SPSS







# Preguntas?

Gracias!!..

Jr.

or lando. joaqui@correounivalle.edu. co

